

Zaimplementować sieć neuronową, która na podstawie odczytu siły sygnału radiowego określi położenie (pozycje) odbiornika.

Koba Bartłomiej - 266493

January 19, 2024

## 1 Opis problemu

### 1.1 Zadanie

Naszym zadaniem było zaimplementowanie sieci neuronowej która na podstawie odczytu siły sygnału radiowego określi położenie (pozycje) odbiornika. Do dyspozycji zostały dopuszczone biblioteki które wspomagają realizację sieci neuronowych takie jak Tensorflow czy PyTorch.

### 1.2 Narzędzia wykorzystane do realizacji zadania

W swojej implementacji sieci realizującej zadanie zdecydowałem postawić na bibliotekę PyTorch, która to cechuje się znacznie mniejszym poziomem abstrakcji w stosunku do biblioteki Tensorflow.

### 1.3 Dataset

Naszymi danymi wejściowymi był odczyt siły sygnału z 16 nadajników radiowych. Wyjściem natomiast była pozycja (x,y) odbiornika.

## 2 Zastosowane parametry sieci

### 2.1 Stałe parametry

Podczas prototypowania zdecydowałem się na ograniczenie liczby epok do 5000. Przy relatywnie niskim skomplikowaniu i rozmiarze sieci 5000 epok wystarcza aby otrzymać wartościowy wynik. Jako aktywator został zastosowany tangens hiperboliczny, do inicjalizacji wag początkowych zostało wykorzystanie pojedyncze losowanie z rozkładu normalnego w przedziale od  $-\frac{1}{\sqrt{n}}$  do  $\frac{1}{\sqrt{n}}$ , gdzie n to liczba wyjść.

### 2.2 Ogólny kształt sieci

W tej pracy rozważane będą następujące sieci:

- Dwie warstwy ukryte, neurony na warstwie: [32, 8]
- Cztery warstwy ukryte, neurony na warstwie: [64, 256, 64, 8]
- Dwie warstwy ukryte, neurony na warstwie: [128, 8]

### 2.3 Algorytm Uczenia

- Stochastic Gradient Descent to klasyczny algorytm optymalizacji używany do trenowania modeli maszynowych. W ramach każdej iteracji, SGD aktualizuje parametry modelu, zmniejszając funkcję straty w kierunku przeciwnym do gradientu tej funkcji.

- Adam jest bardziej zaawansowanym algorytmem optymalizacji, łączącym zalety metod momentum i RMSprop. Oparta na estymacji pierwszego momentu (średnia ruchoma gradientów) i drugiego momentu (średnia ruchoma kwadratów gradientów), Adam dostosowuje współczynniki uczenia dla każdego parametru indywidualnie.

## 3 Wyniki

### 3.1 SGD




Figure 1: Sieci 32-8 i SDG lr=0.6

```
Fold 1/4 - Last Epoch Training Loss: 0.0005166819901205599, Validation Loss: 0.0005454607307910919
True: 0.0021355939097702503, -0.07411415874958038
Pred: -0.013803900219500065, -0.04882561042904854
Fold 2/4 - Last Epoch Training Loss: 0.0004940133658237755, Validation Loss: 0.0005006850697100163
True: 0.04697994515299797, 0.07233665883541107
Pred: 0.06355439126491547, 0.07892552018165588
Fold 3/4 - Last Epoch Training Loss: 0.0004964394029229879, Validation Loss: 0.0004938688362017274
True: -0.07683811336755753, -0.017587298527359962
Pred: -0.08379489183425903, -0.023486539721488953
Fold 4/4 - Last Epoch Training Loss: 0.0005101357819512486, Validation Loss: 0.0005315011367201805
True: -0.01756419613957405, -0.000401869387133047
Pred: -0.015424739569425583, -0.03034920059144497
```




Figure 2: Sieci 64-256-64-8 i SDG lr=0.6

Fold 1/4 - Last Epoch Training Loss: 0.0005178599967621267, Validation Loss: 0.0005442940746434033  
 True: 0.03247545287013054, -0.008672832511365414  
 Pred: 0.044988419860601425, -0.0361560694873333  
 Fold 2/4 - Last Epoch Training Loss: 0.000505793490447104, Validation Loss: 0.000509492470882833  
 True: -0.022430654615163803, 0.0030060356948524714  
 Pred: -0.038116540759801865, 0.02877528965473175  
 Fold 3/4 - Last Epoch Training Loss: 0.0005093671497888863, Validation Loss: 0.0005195978446863592  
 True: 0.01325552724301815, -8.132308721542358e-05  
 Pred: 0.012276910245418549, -0.0018427519826218486  
 Fold 4/4 - Last Epoch Training Loss: 0.0005172077799215913, Validation Loss: 0.0005486318841576576  
 True: -0.08415034413337708, -0.015442697331309319  
 Pred: -0.12416870146989822, -0.025070229545235634

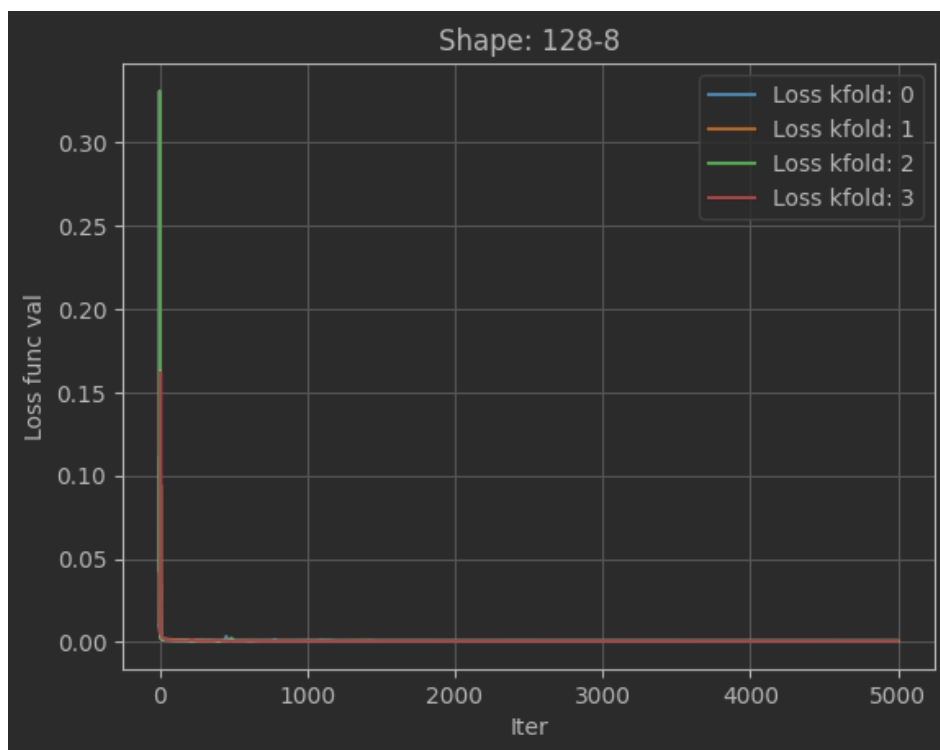


Figure 3: Sieci 128-8 i SDG lr=0.6

Fold 1/4 - Last Epoch Training Loss: 0.0004997126525267959, Validation Loss: 0.0005228188238106668  
 True: 0.10350506007671356, -0.0672144889831543  
 Pred: 0.14051960408687592, -0.05093720182776451  
 Fold 2/4 - Last Epoch Training Loss: 0.0005175122641958296, Validation Loss: 0.0005272841663099825  
 True: 0.06303107738494873, 0.01463069673627615  
 Pred: 0.07269001752138138, 0.020328929647803307  
 Fold 3/4 - Last Epoch Training Loss: 0.00045517730177380145, Validation Loss: 0.0004746193590108305  
 True: -0.023316843435168266, 0.01581977866590023  
 Pred: -0.02868618071079254, -0.027181819081306458  
 Fold 4/4 - Last Epoch Training Loss: 0.0004584943817462772, Validation Loss: 0.0004810068348888308  
 True: -0.10280121862888336, 0.04091782122850418  
 Pred: -0.06463944911956787, 0.03035897947847843

## 3.2 Adam




Figure 4: Sieci 32-8 i Adam lr=0.1

Fold 1/4 - Last Epoch Training Loss: 0.0043173059821128845, Validation Loss: 0.004300277680158615  
True: 0.008332774974405766, 0.009511228650808334  
Pred: -0.07966910302639008, 0.09212295711040497  
Fold 2/4 - Last Epoch Training Loss: 0.0057052806951105595, Validation Loss: 0.005713103339076042  
True: 0.006617660168558359, 0.05628501623868942  
Pred: -0.0018686109688133001, -0.03246079012751579  
Fold 3/4 - Last Epoch Training Loss: 0.004705663304775953, Validation Loss: 0.004867066163569689  
True: 0.019097628071904182, -0.025766776874661446  
Pred: -0.10707610100507736, -0.039323460310697556  
Fold 4/4 - Last Epoch Training Loss: 0.0016928327968344092, Validation Loss: 0.0023339048493653536  
True: -0.04914947226643562, 0.035108331590890884  
Pred: 0.0004889771225862205, -0.0013148549478501081

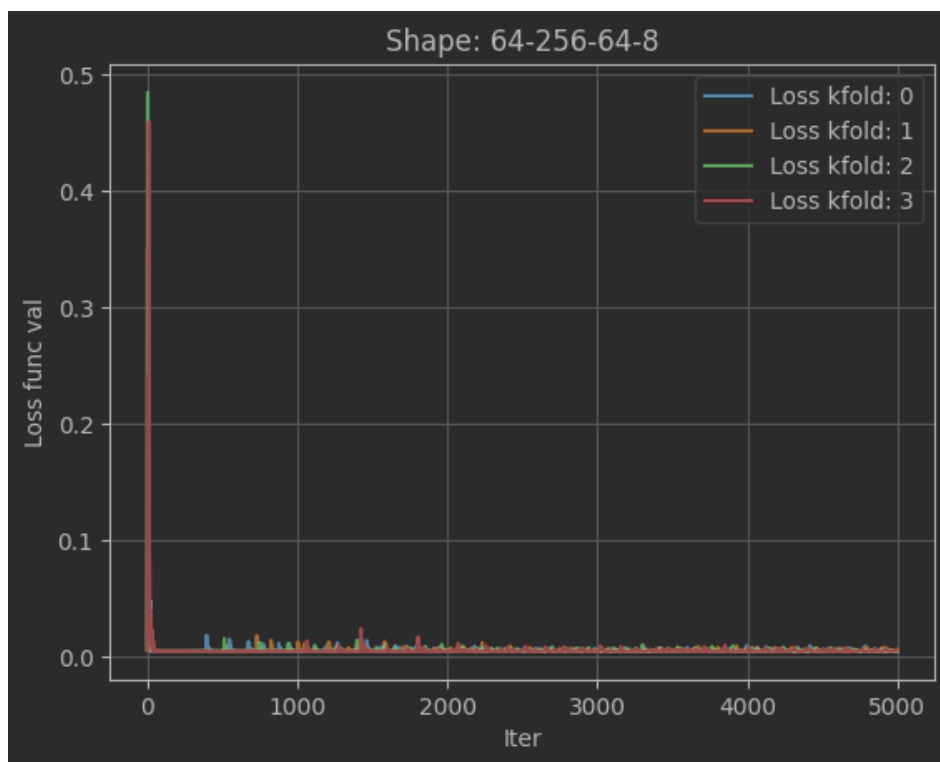


Figure 5: Sieci 64-256-64-8 i Adam lr=0.1

Fold 1/4 - Last Epoch Training Loss: 0.004310098942369223, Validation Loss: 0.004321989603340626  
 True: 0.012881102971732616, -0.006670048460364342  
 Pred: 0.09336797893047333, -0.0044822390191257  
 Fold 2/4 - Last Epoch Training Loss: 0.005824584048241377, Validation Loss: 0.005891980137676001  
 True: 0.002589160343632102, -0.06236468628048897  
 Pred: 0.11458619683980942, 0.03563794866204262  
 Fold 3/4 - Last Epoch Training Loss: 0.00442627165466547, Validation Loss: 0.004629801958799362  
 True: 0.006238558329641819, -0.02194989286363125  
 Pred: 0.04616720974445343, 0.020328929647803307  
 Fold 4/4 - Last Epoch Training Loss: 0.005209604278206825, Validation Loss: 0.005601956974714994  
 True: 0.00862055512607098, -0.04821380227804184  
 Pred: -0.0961722582578659, 0.034054260700941086




Figure 6: Sieci 128-8 i Adam lr=0.1

Fold 1/4 - Last Epoch Training Loss: 0.005030693951994181, Validation Loss: 0.00523329246789217  
 True: 0.008007489144802094, -0.04391389340162277  
 Pred: -0.12446340173482895, 0.0007967337733134627  
 Fold 2/4 - Last Epoch Training Loss: 0.004628455266356468, Validation Loss: 0.0042379023507237434  
 True: 0.005115106701850891, -0.021203884854912758  
 Pred: 0.09346620738506317, -0.10372690111398697  
 Fold 3/4 - Last Epoch Training Loss: 0.004366617649793625, Validation Loss: 0.004717047791928053  
 True: -0.009133233688771725, 0.019690917804837227  
 Pred: -0.08379489183425903, -0.023486539721488953  
 Fold 4/4 - Last Epoch Training Loss: 0.004268405959010124, Validation Loss: 0.004273941740393639  
 True: -0.015318223275244236, 0.001249655382707715  
 Pred: -0.08143729716539383, 0.03194266930222511

## 4 Wnioski

Na ten moment nie dysponujemy rozwiązaniami pozwalającymi w matematyczny sposób określić najlepszy zestaw zmiennych który przełoży się na jakość predykcji. Duża rola w projektowaniu odgrywa doświadczenie osoby tworzącej model. W tym konkretnym przypadku najlepsze wyniki udało się osiągnąć dla Sieci 128-8 i SDG o parametrze lr=0.6, co osobiście jest dla mnie zaskoczeniem, ponieważ myślałem że sieć o 4 warstwach ukrytych.